

Transformer开始构建三维世界：开源模型几张图片秒级生成可探索3D场景

原创 关注AI的 机器之心 2026年8月5日 14:10 湖北 24人

Minds in AI.


编辑 | Sia、晓楠

从 2D 像素到 3D 场景 Query，影溯正在尝试把三维内容生产推向可规模化调用的新阶段。

围着桌上的小摆件随手拍几张照片，几秒后，有趣的一幕发生了。


它们竟从二维照片中「立」了起来，变成了一个可以把玩的 3D 内容。

没有扫描、几乎不用等待，咔嚓几下就能生成。




我又用手机从不同角度给楼下的咖啡店拍了 6 张照片。这个空间也立刻被保存在了手机里。







就连家里的卧室，也在咔嚓几声后，变成了一个可以自由探索的 3D 空间。




聚餐、桌搭、毕业、搬家、婚礼、日常生活 手机能随手记录下当下重要的时刻，把能进入的场景发给身边的朋友，真的十分有趣。





这款 App 叫 **Crystal^Q 空间相机**，是影溯（InSpatio）将最新研究成果做成的一款免费 3D 捕捉工具，让每个人都能轻松体验亲手拍摄 3D 空间照片的感觉。


这背后的技术，是影溯正式开源的前馈式 3D Gaussian Splatting 生成技术 QuerySplat。只需输入**少量**不同视角、**无需**提供相机位姿的图片，即可在一次前向推理中，**秒级**生成可自由切换视角的 3D 场景。



在大规模 DL3DV-Evaluation 基准的 2、4、12 视图设置中，Topos-Lite 在 PSNR 和 SSIM 指标上均取得**最优结果**；在更关注感知相似度的 LPIPS 指标上，也在 2 视图和 4 视图设置中**排**

名第一。

更直观的变化是，模型生成的物体边缘更锐利、纹理更清晰，跨视角结构也更稳定。



同样输入5张图片后，与其他方法相比，Topos-Lite生成结果（Ours）中的主体轮廓更完整，纹理更清晰，场景结构也更加干净稳定。

这一次，影溯选择将 QuerySplat 开源，不只是公开一项技术成果，更希望推动前馈式 3D 生成从少数团队的前沿探索，走向整个行业可以共同验证、持续迭代的技术基础，加速 3D 内容生产真正迈向规模化，并创造出更多好玩的 3D 应用。

- 项目主页：
<https://inspatio.github.io/querysplat/>
- GitHub 与模型权重：
<https://github.com/inspatio/querysplat>
- 技术报告：
<https://arxiv.org/abs/2608.01186>



从像素到场景：
让 Transformer 不再只围着二维图片工作

Topos-Lite 最值得关注的地方，并不只是把 3D 场景做得更清楚，而是**改变了模型组织三维空间的方式**。




Figure 2: **Method Overview.** A frozen Vision Geometric Model (VGM) encodes geometry-aware memory and defines cameras. Geometry queries decode spatial Gaussian parameters from VGM features, while appearance queries read RGB/Plücker appearance memory to predict opacity and SH colors. The assembled Gaussians are trained by differentiable splatting in the VGM-defined coordinate system.

Topos-Lite 架构图

过去不少前馈式 3DGS 方法采用**像素对齐 (Pixel-Aligned)** 的范式。可以把它理解为：模型先从每张图片的每个像素出发，预测这个像素在三维空间里对应什么，再把大量预测组合成一个场景。

但它有一个**先天问题**：高斯点仍然被牢牢绑定在二维图像的像素和相机射线上。不同视角中的像素稍有误差，就可能在三维空间里产生冲突，最终表现为重影、漂浮、结构偏移，或者大量小尺度、低效率的高斯球。

这有点像几个人从不同角度给同一只花瓶描轮廓，再把几张透明描图纸叠在一起。理想情况下，瓶口、瓶身和底座应该准确重合。但只要其中一张稍微画偏，叠起来就会出现双重轮廓，周围还可能留下零散的线条。

Topos-Lite 采用的是 **Query-based** 的思路。

它不再要求每个高斯点首先属于某一个像素，而是**让一组可学习的 Query 充当「场景级位置」**。每个 Query 可以跨越不同图片、不同区域聚合信息，再在连续三维空间中生成一组 Gaussian Primitives。

这让 Transformer 熟悉的 Query 和 Attention 机制，在这项工作中真正承担起组织三维场景的角色：Query 不再只是围绕二维 Token 工作，而是成为连续三维空间中的场景槽位。

少量图片、无需手动标定、秒级生成




Figure 1: **QuerySplat overview.** Given uncalibrated images with varying view counts, QuerySplat reconstructs clean and high-fidelity 3D Gaussian scenes in a pose-free, feed-forward, and non-pixel-aligned manner. Compared with prior methods, it produces substantially more coherent scene structure while supporting in-the-wild inputs within seconds.

只需输入数量不等、未经相机标定的随手拍照片，模型便能在无需相机位姿的情况下，通过一次前向推理快速生成可由切换视角的3D Gaussian场景。与其他方法相比，其生成结果中的主体轮廓更完整，纹理更清晰，场景结构也更加干净稳定。

传统高质量 3DGS 往往需要围绕一个场景采集大量图片，获得或计算相机参数，再对这个场景单独进行较长时间的优化。它可以得到很好的结果，但每遇到一个新场景，就要重新做一遍。

前馈模型改变的是成本结构。模型训练完成后，面对一个新场景，不再从头优化，而是直接完成一次预测。就像图像生成模型不会为每张新图片重新训练一样，3D 场景生成也开始从每个项目单独制作，变成一种可以被重复调用的通用能力。


对普通用户而言，这带来**三个最直接的变化**：需要拍摄的图片更少、不需要手动提供专业相机标定信息、等待时间从传统流程压缩到秒级。

Method	Pose-free	2 views			4 views			12 views		
		PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
DepthSplat (2025)	$\times$	20.5357	0.6721	0.2592	22.9079	0.7683	0.1853	21.6785	0.7549	0.2050
TokenGS (2026)	$\times$	20.4258	<u>0.6736</u>	0.3783	<u>23.2704</u>	0.7565	0.3026	21.8094	0.6960	0.3696
YoNoSplat (2025a)	$\times$	19.8356	0.6296	0.2909	22.8488	0.7469	0.1987	<u>22.7326</u>	<u>0.7608</u>	0.1958
AnySplat (2025)	$\checkmark$	14.0742	0.4447	0.4475	17.3938	0.5483	0.3418	19.6253	0.6334	0.2989
NoPoSplat (2025b)	$\checkmark$	19.0650	0.5997	0.3164	—	—	—	—	—	—
SPFSplat (2025)	$\checkmark$	19.1163	0.5874	0.3046	—	—	—	—	—	—
SplatWeaver (2026)	$\checkmark$	15.6953	0.4991	0.3666	19.2413	0.6294	0.2715	20.4047	0.6683	0.2515
YoNoSplat (2025a)	$\checkmark$	19.1675	0.5908	0.3081	21.9644	0.6983	0.2167	21.6323	0.6953	0.2184
Ours	$\checkmark$	21.3888	0.6990	0.2585	24.5765	0.8002	0.1843	23.7005	0.7685	0.2297
Ours + TTO20	$\checkmark$	22.0094	0.7168	0.2478	26.2524	0.8304	0.1591	27.0003	0.8472	0.1667
Ours + TTO50	$\checkmark$	21.9437	0.7149	0.2463	26.3779	0.8321	0.1537	27.7199	0.8615	0.1464

Table 1: Interpolation results averaged over the large, medium, and small splits. Higher PSNR/SSIM and lower LPIPS are better. **Bold** and underlined values indicate the best and second-best results, respectively; TTO variants are excluded from this comparison. See Appendix A for complete results for each view setting and split.

从结果来看，Topos-Lite 在 DL3DV-Evaluation 的多种稀疏视图设置中取得了**当前最强**的整体表现。

特别是在 4 视图设置中，模型在 **PSNR、SSIM 和 LPIPS 三项指标上均排名第一**。即使只输入两张图片，它也保持了领先的结构和渲染质量。



定性比较。

SOTA 效果之外，Topos-Lite 还提供了明确的**容量扩展接口**。

训练过程中，Query 数量可从 1,024 逐步扩展至 8,192，每个 Query 解码一组 Gaussian Primitives。更强的几何骨干、更大的 Decoder、更多 Query，以及更高分辨率的外观特征，都可以分别扩展。

这还不能被简单称为已经证明了「3D Scaling Law」，但它至少说明了一件重要的事：前馈化解决了新场景的边际生成成本，Query 化则为场景表达容量留下了继续扩展的入口。速度和质量不再必须二选一。

值得一提的是，Topos-Lite 的性能还处于早期研究阶段，远未触及天花板。在数据规模效应的持续驱动下，其 **3D 生成的品质与精细度将持续跃升**；更值得期待的是，**未来该模型将有能力在端侧高效运行**，实现3D内容的本地化快速生成，解锁更广阔的应用场景。

下一代人工智能为什么一定要理解空间？

在影溯看来，过去十年，人工智能主要在学习人类已经表达出来的世界，而下一阶段，它需要进一步理解世界本身。语言是智能理解人类文明的入口，空间则是智能进入真实世界的基础。

图片和视频当然包含丰富的空间线索，但本质上仍然是三维世界在特定时间、特定视角下的二维投影。同一个房间可以拍出无数张不同画面，但背后不变的仍是房间本身的三维结构。

因此，**二维更像是 Observation，三维则更接近 State。**

如果模型只从二维像素中学习，它不仅要理解场景，还要反复处理视角、投影、遮挡和光照造成的变化。视频中的大量帧，可能只是在不同位置、不同时间重复记录同一面墙、同一张桌子。模型必须从这些高度冗余的观测中，反推出背后相对稳定的空间结构。

而引入三维，意味着将「世界是什么」和「我们怎样看见世界」分开。模型可以学习一种更紧凑、更稳定的空间表征，并理解这一状态如何在不同视角和条件下生成不同观测。它不必反复记忆大量相似画面，也更有机会持续追踪环境、物体及其相互关系。

这也解释了为什么空间智能并非 AI 的边缘分支。语言模型可以回答「这是什么」和「这意味着什么」，但进入真实世界的机器还必须回答「我在哪里」、「物体之间是什么关系」、「下一步会发生什么」和「我应该怎样行动」。

从数字智能走向物理智能，**空间不是一个可选项，而是一项需要掌握的基本能力，更是一道无法绕开的门槛。**

一项技术突破背后，是近二十年的积累

空间智能是一条很难依靠短期追逐热点走通的路线。从相机模型、标定、SLAM，到三维重建和几何优化，再到神经网络训练、数据系统与产品部署，每个环节都有大量不容易被外界看见的工程细节。一项工作在论文里成立，不代表它能在真实环境里稳定运行；一个 Demo 足够漂亮，也不代表它能够以可控成本持续 Scale。

而影溯的核心团队在 SLAM、三维视觉和空间智能领域已有近二十年的积累，早已形成一套贯通基础研究、工程实现与产业落地的能力体系。

二十多年来，影溯创始人章国锋^Q教授一直在追问一个问题——**机器究竟要怎样理解一个真实的三维世界？**

章国锋本科和研究生阶段均就读计算机专业。在研究生阶段，章国锋师从鲍虎军教授，从大型科研项目中的摄像机跟踪问题开始进入三维视觉领域。最早，他要解决的是如何从一段视频中恢复摄像机的运动。随后，问题从离线处理变成实时跟踪，从单一镜头扩展到 SLAM、三维重建和空间智能。

这些技术方向，背后指向的是同一件事：机器不能只看见一帧画面，它还要知道自己在哪里，周围的物体如何分布，不同视角下看到的内容为什么仍然属于同一个空间。

此后，章国锋完整经历了**三维技术**^Q从摄像机跟踪、移动端 SLAM、实时空间重建，到 NeRF、3D Gaussian Splatting、生成式 3D 和世界模型的发展。技术表达不断变化，但核心问题没有改变：如何从有限的二维观测中，恢复、表示并推演背后相对稳定的三维世界。

如果说高校研究让他不断接近这个问题的技术本质，那么，在商汤负责数字空间相关技术和业务的经历，让他看到了另一面：**一项三维技术在论文中成立，与它能否成为真实世界中的基础能力，是两件不同的事。**

三维技术要进入产品，不只要追求精度，还要面对速度、稳定性、设备成本、系统效率和客户交付；要从一次漂亮的 Demo 走向大规模应用，就必须把每个场景单独优化的项目能力，变成可以持续复用和规模化调用的系统能力。

多年来，这种双重身份的淬炼使他能够将空间智能的前沿算法，转化为驱动产业变革的实际动能。而这些来自学术端的理论突破与产业端的落地认知，又经由联合创始人刘浩敏⁹博士及其团队的工程化能力进一步放大，在产业一线完成了模型训练、效率优化与系统验证，让前沿算法得以在有限算力下实现实时响应与极致吞吐。

长期协作带来的价值，远不止彼此熟悉。底层技术研究中，大量问题没有标准答案，技术路线也经常无法被提前证明。团队需要能够快速暴露问题、相互质疑结果，并在信息不充分、方向不确定的情况下，依然形成共同判断。人才可以招聘，设备可以买到，但共同的技术语言、对问题的判断方式，以及彼此之间的信任，只能通过时间形成。

在与影溯的交流中，机器之心发现，影溯的团队结构也颇为特别：**既有长期积累，也保持着年轻团队的活力。**

多位核心成员已在三维视觉领域深耕十余年，围绕 3D 研究积累了长期迭代的基础设施；与此同时，许多年轻研究者也能直接参与核心课题，并承担关键工作。**Topos-Lite 的关键突破，就是由团队中的「00 后」研究员主导完成。**长期积累与年轻研究者的快速成长，在这里并不矛盾，而是共同构成了团队的研究效率。

这种组织方式背后，是影溯对**研究效率的一种判断**：真正有潜力的研究者，应当尽可能接近最重要的问题，并在真实任务中快速成长。年龄、资历和头衔可以作为参考，但不应成为人才参与核心创新的边界。

先进入人的真实场景，再成为机器理解世界的数据

当然，空间智能的终局很大，但三维技术的价值，并不需要等到机器人真正进入千家万户之后才开始显现。更现实的路径，是先降低三维内容的生产门槛，让它进入人们已经存在的记录、展示与创作需求。

首先是空间记录。当三维生成足够简单、快速且低成本，人们可以把几张照片变成能够自由切换视角、重新进入的「空间照片」。即将搬离的第一个家、孩子成长的房间、毕业前的教室，或者

婚礼当天的礼堂，都可以都从一组平面影像变成更完整的空间记忆。过去二维影像成为主流，很大程度上源于它的捕捉、存储和传播成本更低。当三维内容获得接近拍照的使用门槛，记录生活的媒介也可能随之发生变化。

其次是空间展示与远程体验。在房产、酒店、商业展陈、零售门店和室内设计等领域，用户真正关心的往往不只是几张精心选择的平面图片，还包括空间布局、物体之间的关系，以及人在其中移动时看到的变化。通过少量现场照片快速生成可浏览的三维场景，可以让看房、选房、展厅参观、装修沟通和商品陈列拥有更直观的表达方式，也能降低传统三维采集和内容制作的成本。

还有生成式内容生产。对游戏、影视和互动内容创作者而言，这意味着二维生成、视频制作和三维场景之间可以建立更直接的连接。未来，一段生成视频或几张概念图，可能进一步转化为可自由浏览、继续编辑和用于虚拟拍摄的三维资产，从而进入游戏、影视、电商和互动内容等工作流。

而对机器人而言，这些三维世界有着更重要的意义。当场景进一步拥有物体语义、动态变化和物理规律，它们就不再只是供人观看的内容，也可以成为机器进行仿真、验证和学习的训练场。机器人可以在进入真实世界之前，先在无数可生成、可控制、可重复的虚拟世界中经历环境、理解空间、学习行动。

先让三维技术进入真实场景，再让真实使用产生的数据训练更强的空间智能，这可能是三维数据走向规模化的一条现实路径。

终局：让智能真正进入空间

今天，「世界模型」已经成为一个被广泛使用的概念。从视频生成、可交互游戏环境，到机器人控制系统，不同技术路线都被纳入世界模型的讨论。

对影溯而言，**世界模型是实现目标的技术路径，空间智能才是长期方向。**

它希望构建的，是一种能够在现实世界中验证自身空间理解能力的智能：知道自己在哪里，理解物体、环境与自身之间的关系，能够预测世界如何变化，也能判断行动将带来什么结果。

显然，Topos-Lite 还不是这个终局。但它解决了其中一个基础且现实的问题：让 Transformer 借助明确的三维结构，从少量二维观测中快速组织出稳定、清晰、可渲染的三维场景。

更重要的是，它也让影溯关于空间智能的长期判断，落实到可以公开体验、量化评测和持续迭代的技术结果上。

未来的空间智能会继续沿着 Transformer 演进，还是转向 JEPA 或尚未出现的新架构，目前仍无定论。但无论架构如何变化，只要机器需要进入真实世界，空间理解就无法绕开；要形成这种能力，也离不开大规模、高质量的 3D、4D 数据，以及持续降低数据生产成本的基础设施。

而在这一庞大的叙事中，影溯希望参与建设的，正是这套面向物理智能的模型、数据与工程基础设施。未来的机器人、智能汽车、智能眼镜和新型终端形态各异，却都需要一颗“大脑”，去理解自身所处的空间，并据此感知、预测和行动。

Topos-Lite 则是这条长路上的一次阶段性证明：三维场景可以生成得更快、更清晰，也可以更开放地被调用；Transformer 的处理对象，也开始从语言和二维 token 延伸到连续三维空间。

当空间能够像图片和视频一样被低成本记录、生成和分享，一个属于三维内容的新网络，或许才刚刚打开入口.....



影溯科技长期诚挚邀请三维视觉、AIGC、世界模型、多模态大模型、AI Infra、AI 系统工程师、AI 产品及人工智能前沿研究的研究者与工程师加入，共同探索空间智能和三维世界模型的更多可能。招聘详情请关注“影溯科技”微信公众号，也欢迎通过 hr@inspatio.com 投递。

© THE END

转载请联系本公众号获得授权

投稿或寻求报道：liyazhou@jiqizhixin.com

